弈宝 for《王者万象棋》问答 Agent 设计文档

本项目面向《王者万象棋》玩家，提供原创游戏向导“弈宝”。目前已完成网页交互、意图识别、知识检索、回答生成、来源展示和离线评测，支持基础知识问答、局面建议、连续追问及日常闲聊。

1. 运行方法

依赖与已验证环境：项目已在 Windows、Python 3.11.5 环境运行验证。后端使用 FastAPI，前端使用原生 HTML/CSS/JavaScript，知识检索使用 BGE 中文嵌入模型与 Qdrant 本地向量库。依赖清单见 `requirements-dev.txt`，锁定版本见 `requirements-lock.txt`。

安装与模型配置： 在项目根目录执行：

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements-dev.txt
if (-not (Test-Path .env)) { Copy-Item .env.example .env }
```

编辑 `.env`，填写模型服务地址 `LLM_BASE_URL`、密钥 `LLM_API_KEY` 和模型名称 `LLM_MODEL`，使用 `AGENT_MODE=live`、`RETRIEVAL_BACKEND=vector`。我的评测使用 deepseek-v4.1-flash，默认设置 `LLM_THINKING=disabled`。

启动： 首次运行建立向量索引，再启动服务：

```
.\.venv\Scripts\python.exe -m scripts.index_knowledge
.\.venv\Scripts\python.exe -m uvicorn app.main:app --host 127.0.0.1 --port 8000
```

浏览器访问 `http://127.0.0.1:8000`。嵌入模型和向量库分别缓存于 `data/models/`、`data/vector/`，后续启动可直接复用。

评测： 停止占用本地向量库的网页后端后，执行固定集评测和工程测试；每次实验使用新的报告目录

```
.\.venv\Scripts\python.exe -m eval.run --mode live --output eval/reports/my-run
.\.venv\Scripts\python.exe -m pytest -q
```

2. 接口与流程

接口输入输出： `POST /api/chat` 接收玩家问题 `message` 和对话历史 `history`，返回回答 `answer`、意图 `intent`、状态 `status`、引用资料 `sources` 和响应耗时 `latency_ms`。同时记录检索计划、模型调用和阶段耗时，供问题定位使用。页面支持连续对话、清空会话、等待提示及来源展开；网络或服务异常时保留原问题并提供重试。

请求头使用 `Content-Type: application/json`。`history` 首次请求可为空数组，后续按 `user`、`assistant` 的顺序传入。`intent` 对应 `knowledge`、`advice`、`chitchat`、`out_of_scope`；`status` 表示已回答、部分回答、待澄清、资料不足或范围外。无引用时 `sources` 为空数组，耗时单位为毫秒。完整字段可在服务启动后通过 `/docs` 查看。

上下文管理： 分类规划与回答生成接收同一段按角色排列的近期对话，以及本轮问题。历史保留最多24条、合计24000字符，超过预算时移除最早轮次。模型结合历史理解指代、承接列表和识别话题切换。

意图路由： 大模型在一次调用中完成意图判断、上下文理解、澄清判断和检索规划。

意图	处理方式
游戏知识问答	检索相关规则或对象资料后回答
游戏情境建议	结合已有条件检索并给建议，缺少关键条件时追问
日常闲聊	直接生成简短、自然的回应
能力范围外请求	根据具体请求说明限制并提供可行的下一步

检索与生成的调用关系： 知识和建议通常使用两次模型调用，闲聊、范围说明和澄清通常一次。分类与生成共用向导角色提示，保持亲和、直接的交流方式。

3. 知识库设计

知识结构与来源： 我从官网基础资料起步，但是发现官网资料太少，然后加入了 万象棋知识站 Wiki。当前共7731条知识片段，包括30条官网基础知识和7701条 Wiki 片段，覆盖英雄、棋手、天赋、装备、效果牌、机制、攻略及版本记录等内容。

知识单元、字段与主题： 知识以一条规则或一个对象的具体字段为单元，例如分别保存英雄的普通卡面、觉醒效果和战斗技能。这样能够让检索直接对应玩家所问的内容，保留完整的数值与触发条件，也便于独立更新和逐条引用；长篇攻略分段存储，并保留同一文档的关联关系。

字段分组	主要内容	组织目的
知识内容	唯一编号、主题、标题、正文	按基础规则、英雄、棋手、天赋、装备等主题归类
对象信息	栏目、实体名、具体字段、玩法、别名	区分对象及普通卡面、觉醒、技能等内容，支持精确筛选
来源信息	来源标题、链接、采集日期	支持原文追溯和资料更新
适用与核验	版本范围、内容类型、核验层级	区分官方原文、Wiki资料、站方解释及待确认内容

检索方法、同义词与多轮追问： 初版采用关键词检索，资料扩展后改为向量检索。大模型根据问题和上下文生成检索计划，BGE编码查询，Qdrant召回候选，再结合实体、标题、别名和词法匹配排序，并按玩法及版本范围筛选。多对象、技能或觉醒查询会补齐对应字段；情境建议追加费用、收益及触发条件等资料。

同义词和黑话通过别名元数据、模型语义理解共同处理，例如“升本”对应升级、“卖牌”对应出售英雄牌，“棋手李白”对应白歌。游戏简称及口语表达由模型结合当前游戏范围和对象目录还原为检索问题。多轮追问同时输入近期历史与本轮消息，承接上文的对象、列表和局面条件，再检索对应资料。

未命中、资料冲突与版本处理：

- 未命中时说明本次缺少的资料，必要时请玩家补充游戏内描述；已有部分依据时先回答能确定的内容，并展示相应来源。
- 冲突处理结合玩法、版本、卡牌状态和来源层级进行区分，分别呈现普通卡面、觉醒或不同版本的效果。标记为待确认的机制单独说明；其余差异由模型结合来源信息解释，仍需核验的部分保留出处并提示待确认。
- 版本不明确时说明当前资料的采集日期和适用范围，必要时确认玩家所在玩法或版本；历史资料按查询需求参与检索。

更新方式与规模演进： 当前更新流程为"采集并归档快照—构建知识记录—核对覆盖与来源—重建向量索引—回归评测"。原始资料随工程保存，可从快照重新构建知识库；更新后检查索引与知识版本是否一致。

4. 离线评测

测试覆盖： 固定集包含37例、49轮请求，覆盖四类意图、6组多轮对话，以及资料不足、条件缺失、未接入能力和指令干扰等场景。每例记录预期意图、行为、回答要点、禁止项及相关知识编号。评测与网页共用 `Agent.chat`，通过真实前轮回答推进多轮对话。

评价方法： 自动评价检查关键事实、禁止断言、处理状态、引用原文和来源完整性；情境建议增加行动、条件、机会成本、调整条件与证据边界五个维度。报告分别统计意图准确率、检索命中率、回答规则通过率、正常完成率和耗时，并保存逐轮输出。评测标签仅用于评分器。

指标	结果
意图准确率（49轮）	49/49
检索命中率（34轮需资料的问题）	34/34
回答规则通过率（49轮）	46/49
正常完成率（49轮）	48/49
返回内容的比例（49轮）	49/49

人工抽查： 我通过手动提问白歌技能、苏烈觉醒效果、河洛天赋追问等，测试出来许多问题，并将测试出的问题逐一修复，具体问题见第6节（亲自检查并推动修正的例子）。测试集合中也包含我人工给出的提问。

最后一次交付前我进行的测试（未在测试集中）：

提问	回答
小乔的技能是什么	小乔的技能叫「甜蜜恋风」：她会持续引导1道旋风吹起最近的敌人，让目标浮空，并且每0.2秒受到10%法术攻击力的法术伤害，最多持续3秒。 这个技能会随等级变强： - 10级：旋风伤害提升到15%法术攻击力。 - 40级：再额外吹起1名附近敌人。 - 100级：还会额外吹起1名最远的敌人。 所以小乔是远程法师，技能主要靠浮空控住敌人并持续造成法术伤害，升级后能同时影响更多目标。
觉醒之后呢	小乔觉醒后，技能机制会从「随机3名英雄等级+1」变成全员提升：卡面原文写的是每当你的英雄触发登场效果时，随机3名英雄等级+1；觉醒后则是每当你的英雄触发登场效果时，所有英雄等级+1。也就是说触发条件没变，都是英雄触发登场效果，但受益范围从随机的3名扩大到全体英雄。
王者荣耀里小乔的技能	明白了，你问的是《王者荣耀》里的小乔。两边的技能不能直接套用，我这边只负责《王者万象棋》的资料，没有《王者荣耀》的技能数据可以给你比对。想看的话，游戏内的英雄介绍里就有小乔的完整技能说明。

提问	回答
一般来说怎么D牌比较优啊	这个「怎么D牌最优」我没法给出一套通用答案--手头没有刷新费用、商店概率、各等级卡池这些资料，硬讲个节奏出来就是编了。 不过方向可以这么把握:D牌本质是用经济换牌面成型，值不值取决于你当时缺几张、离成型还差多少。一般会更值得刷新的时候，是手里已经有两张、只差一张就能合成，或快到某个关键节点需要凑齐阵容;相反，如果只是「感觉牌不好」就猛刷，很容易把经济耗空，牌也没成型。有一个成就叫「无情的刷新机器」，是单个回合用效果牌后刷新商店至少200次，能看出刷新是能堆量的操作，但什么时候刷、刷多少还是得看你自己的局面。 想让我给具体建议的话，告诉我你现在几级、攒了多少能量、阵容差几张牌，咱们一起看这轮该不该D、D多少。

5. 效率与取舍

实际投入时间：大约2天，24小时（10-13上午 至 10-14 晚上）。

响应耗时： 49轮测试的中位耗时为7.04秒，P95为10.75秒；分类规划、检索、生成阶段中位耗时分别为2.18、2.01、2.47秒。优化主要包括合并意图与检索规划、减少重复向量查询、精简无关输入，以及复用网络连接。

简化与限制： 交付范围聚焦单游戏、单向导和本地运行，会话保存在浏览器内存，采用本地向量库，账号、战绩和实时对局尚未接入。当前仍有3轮回答规则未通过，涉及卡牌费用推断、多对象指代和升级建议条件一致性；这些是下一轮质量改进的重点。本地向量库采用单进程访问，后续可根据并发需求迁移服务端部署。

6. AI 开发过程

工具与分工： 我使用 Codex（GPT 6-Astra）协助编码、资料处理、测试排错和文档整理，前端由AI生成，运行时模型为 deepseek-v4.1-flash。我负责确定范围、查找资料、手动测试和提出修改要求，并检查实际回答和评测报告。

亲自检查并推动修正的例子：

1. **知识库更新：** 第一版AI只收录了70条官方知识，我自己找到万象棋wiki，将知识库扩展到7700多条。资料增多后为了提速，把关键词检索改为向量检索。
2. **质量与速度优化：** 我测试时发现追问的上下文没给完整、闲聊回答比较降智，就让AI补全上下文、放宽token限制，并测试思考模式的耗时。刚开始简单问题也要等20s，后来通过压缩检索和判断时间改善，速度得到明显提升。
3. **流程bug修复：** 我问“苏烈觉醒的效果是什么”能得到回答，换成“苏烈觉醒卡面的效果是什么”却说没找到。AI核查发现部分清单查询只取普通卡面就结束检索，资料没给足。修复后，这类查询失败会继续检索知识库，保证给出回答。
4. **基础回答优化：**我发现许多回答都采用了硬编码，导致经常文不对题，就要求改由模型说明能力限制和资料不足，稍微降低了速度，但是明显减少机械感。同时调整Agent的System prompt，让回答更精确、语气更亲和。
5. **意图模块修正：** 最初按关键词分类不够灵活，我让AI改为模型判断，效果明显改善。在思考如何优化过程中，我有考虑过加入TypeSafe的Jev模型去做意图判断，这样速度更快token消耗也更少。但这一版效果不错，加入Jev的边际收益比较低，后续如果需要可以尝试。
6. **加入黑话词库：** 我说“一直吃老六一直输，好难过”，模型却理解成“被老六偷鸡”，没理解成“一直当第六名”。所以我补充了“吃老六”“升本”“速六”等黑话，减少理解错误。